Phân tích bệnh lá lúa và cà phê từ ảnh điện thoại

BÁO CÁO BÀI TẬP LỚN MÔN XỬ LÝ ẢNH

Phương pháp truyền thống với ExG và HSV, K-means trong Lab, đặc trưng màu và kết cấu, phân lớp k-NN

Trường và khoa [Nhóm điền theo mẫu của đơn vị]

Lớp học phần [Nhóm điền]

Giảng viên hướng dẫn [Nhóm điền]

Nhóm thực hiện [Tên nhóm và năm thành viên]

Đề tài theo yêu cầu riêng về bệnh lá lúa và cà phê

Tháng 11 năm 2026

Phạm vi kết quả hiện tại: thực nghiệm phân lớp trên ảnh lúa UCI. Khung xử lý hỗ trợ cả hai cây; thực nghiệm cà phê, ảnh tự chụp và nhãn pixel được hoàn thiện sau khi nhóm bổ sung dữ liệu thật.

Tóm tắt và cam kết học thuật

Báo cáo trình bày một hệ thống phân tích ảnh lá bằng xử lý ảnh truyền thống. Hệ thống tách lá theo màu và hình thái học, gom cụm pixel lá trong không gian Lab để tạo vùng nghi tổn thương, ước lượng tỷ lệ diện tích và trích đặc trưng phục vụ phân lớp. Ứng dụng Streamlit hỗ trợ chụp hoặc tải ảnh, hiển thị các bước và xuất mặt nạ cùng kết quả JSON.

Thực nghiệm ban đầu gồm 90 ảnh huấn luyện và 30 ảnh kiểm tra của bộ Rice Leaf Diseases. k-NN tự cài đạt accuracy 90.0% và macro-F1 0.9019. Đây là đánh giá trên ảnh nền trắng, với nhóm chia theo ảnh vì nguồn chưa có định danh cây hoặc phiên chụp. Kết quả chưa chứng minh khả năng tổng quát ngoài đồng.

Các thuật toán lõi được cài bằng NumPy và kiểm chứng theo cùng quy ước với thư viện. Phép thử thay đổi độ sáng cho thấy độ chính xác giảm mạnh, là bằng chứng cần thu dữ liệu đa điều kiện và cải thiện độ bền ánh sáng trước khi ứng dụng thực địa. Các ngưỡng phân mức là quy ước kỹ thuật, chưa được hiệu chuẩn theo thang nông học.

Cam kết cần được nhóm xác nhận

Nhóm chịu trách nhiệm về dữ liệu thu thập, nhãn bệnh, nội dung giải thích và số liệu nộp cuối. Không sử dụng ảnh mạng để thay ảnh tự chụp; không gọi mặt nạ tự sinh là nhãn tay; không tạo chữ ký hoặc lịch sử commit hồi tố. Mọi số liệu thực nghiệm có đường dẫn tới manifest và tệp kết quả tương ứng.

Đại diện nhóm xác nhận sau khi kiểm tra [Họ tên và chữ ký thực tế]

Phân công thực hiện và minh chứng

Bảng phân công sau là kế hoạch đề xuất cho nhóm năm người. Tỷ lệ đóng góp và chữ ký được ghi sau khi đối chiếu công việc thực tế, không mặc định mỗi người đã hoàn thành phần việc được giao.

Bảng mở đầu 1 Phân công dự kiến

Vai trò	Mã và nhiệm vụ	Nội dung báo cáo
TV1 [Tên]	app.py, tích hợp, quản lý repo	Chương 1, kiến trúc, Chương 5
TV2 [Tên]	Lý thuyết và kiểm chứng	Chương 2, mục kiểm chứng
TV3 [Tên]	HSV, Lab, hình thái, K-means	Phân đoạn trong Chương 3
TV4 [Tên]	LBP, GLCM, k-NN, đối chiếu SVM	Đặc trưng và phân lớp
TV5 [Tên]	Dữ liệu, nhãn tay, thí nghiệm	Chương 4 và biểu đồ

Minh chứng gồm commit thật theo tài khoản từng thành viên, nhật ký họp, ảnh gốc và hồ sơ nguồn dữ liệu. Các tệp nhat_ky_nhom.csv và danh_gia_cheo.csv trong thư mục docs cung cấp cấu trúc ghi chép. Thành viên chỉ ký xác nhận sau khi đọc và hiểu các phần liên quan.

Đánh giá cá nhân nên xét chất lượng công việc, khả năng giải thích và mức tham gia thực nghiệm, thay vì chỉ đếm số dòng mã. Mỗi người cần tự chạy toàn bộ pipeline và trả lời được câu hỏi cơ bản về phần của thành viên khác.

Thời gian trong hướng dẫn có hai mốc 3 tuần và 8 tuần. Nhóm cần theo lịch giảng viên xác nhận và ghi nhật ký thực tế. Báo cáo không diễn giải một phiên chuẩn bị mã thành quá trình làm việc đã kéo dài nhiều tuần.

Mục lục và danh mục ký hiệu

Chương 1 Tổng quan bài toán 6

Chương 2 Cơ sở lý thuyết 9

Chương 3 Thiết kế và cài đặt 14

Chương 4 Thực nghiệm và đánh giá 21

Chương 5 Kết luận và hướng phát triển 29

Tài liệu tham khảo 31

Phụ lục Hướng dẫn chạy và hồ sơ nhóm 33

Các tiêu đề có cấu trúc Heading trong Word để cập nhật mục lục tự động sau khi nhóm chỉnh sửa. Số trang của bản PDF dùng bộ đếm ở chân trang.

Bảng mở đầu 2 Ký hiệu dùng trong báo cáo

Ký hiệu	Ý nghĩa
M, N, P	Chiều cao, chiều rộng và số pixel ảnh
L, D	Mặt nạ lá và mặt nạ vùng nghi tổn thương
K, T, μj	Số cụm, số vòng lặp và tâm cụm thứ j
r, s	Tỷ lệ diện tích và độ lệch chuẩn chuẩn hóa
h, q, G	Histogram, mức xám lượng tử và GLCM
k, d	Số láng giềng và số chiều đặc trưng
TP, FP, FN	Dương tính đúng, dương tính sai và âm tính sai

Danh mục hình và bảng

Hình 3.1 Luồng phân tích một ảnh lá 14

Hình 4.1 Ma trận nhầm lẫn k-NN trên 30 ảnh test 25

Hình 4.2 Ảnh test cùng mask lá và overlay 26

Bảng 1.1 Đầu vào đầu ra và ràng buộc 7

Bảng 1.2 Vị trí của các hướng tiếp cận 8

Bảng 2.1 Ví dụ tính tay K-means 12

Bảng 3.1 Cấu trúc mã nguồn 15

Bảng 3.2 Chi phí tính toán 19

Bảng 3.3 Sai số đối chiếu cùng quy ước 20

Bảng 4.1 Phiên bản thư viện đã dùng 21

Bảng 4.2 Phân bố dữ liệu lúa 21

Bảng 4.3 Kết quả phân lớp trên cùng dữ liệu 23

Bảng 4.4 Macro-F1 năm fold theo cấu hình 24

Bảng 4.5 Kiểm tra stress độ sáng 27

Bảng 4.6 Trạng thái dữ liệu cần bổ sung 28

Bảng 5.1 Kết quả so với mục tiêu 29

Các trang trong danh mục tương ứng bản PDF phát hành cùng mã nguồn. Sau khi bổ sung kết quả thực địa, cập nhật mục lục và danh mục theo bản xuất mới.

Chương 1 Tổng quan bài toán

1.1 Bối cảnh và tình huống sử dụng

Trong một tình huống tại ruộng lúa hoặc vườn cà phê, người trồng nhận thấy lá xuất hiện đốm nâu, vùng vàng hoặc phần mô khô. Ảnh điện thoại có thể ghi nhận dấu hiệu để so sánh theo thời gian và hỗ trợ trao đổi với cán bộ kỹ thuật. Bài toán của đồ án là chuyển ảnh đó thành các vùng có thể quan sát, một tỷ lệ diện tích và nhãn phân lớp có điều kiện.

Phát hiện sớm và giảm sử dụng thuốc bảo vệ thực vật là động lực ứng dụng. Đồ án chưa có thử nghiệm can thiệp hoặc theo dõi năng suất, vì vậy không xem các lợi ích này là kết quả đã đo. Màu vàng có thể xuất hiện do bệnh, thiếu dinh dưỡng, già hóa hoặc chiếu sáng; một ảnh đơn không đủ phân biệt chắc chắn mọi nguyên nhân.

Field Shift trong NASA Space Apps 2026 đặt bài toán nông nghiệp trong bối cảnh dữ liệu quan sát Trái Đất [1]. Ảnh lá cung cấp quan sát ở cấp độ gần mặt đất, còn vệ tinh phản ánh trạng thái theo vùng và thời gian. Hai nguồn có thể bổ sung nhau khi có giao thức địa lý và thời gian phù hợp; báo cáo hiện tại chưa tích hợp dữ liệu vệ tinh và không dùng ảnh vệ tinh thay nhãn bệnh trên lá.

Đóng góp kỹ thuật của đồ án nằm ở pipeline giải thích được, thuật toán lõi tự cài và quy trình tái lập. Người học nhìn thấy mặt nạ trung gian, hiểu cách tỷ lệ được tính và truy được từng kết quả về ảnh gốc. Cách tiếp cận này phù hợp mục tiêu môn Xử lý ảnh và tạo mốc so sánh cho mô hình học sâu trong tương lai.

1.2 Người dùng và quyết định hỗ trợ

Người dùng demo chọn đúng cây trồng và chụp một lá rõ nét. Kết quả phục vụ sàng lọc và ghi nhận triệu chứng. Khuyến nghị của demo tập trung chụp bổ sung, theo dõi và xác nhận chuyên môn. Mô hình không đưa hoạt chất hoặc liều phun từ một nhãn dự đoán.

1.3 Phát biểu bài toán và mục tiêu

Bảng 1.1 Đầu vào đầu ra và ràng buộc

Thành phần	Đặc tả
Đầu vào	Ảnh RGB 8 bit JPG/PNG, một lá chủ đạo, cây lúa hoặc cà phê
Tiền xử lý	Chuẩn hướng EXIF, cạnh dài tối đa 256 pixel, giữ tỷ lệ ảnh
Đầu ra	Mask lá, mask nghi tổn thương, tỷ lệ, mức độ, nhãn hoặc từ chối
Tài nguyên	CPU, không yêu cầu GPU; thời gian được đo trên dữ liệu thật
Giao diện	Tải ảnh, camera, ảnh mẫu; tải PNG và JSON
Tái lập	Seed 42, manifest, cấu hình, phiên bản thư viện và model NPZ

Mục tiêu thứ nhất là triển khai đủ năm chức năng bắt buộc, cho phép truy vết trung gian và tái sử dụng cùng mã cho hai cây. Mục tiêu thứ hai là kiểm chứng các phép toán có quy ước tương ứng với thư viện. Mục tiêu thứ ba là báo cáo accuracy, macro-F1, IoU và ảnh hưởng điều kiện chụp theo giao thức đã xác định trước.

Tiêu chí hoàn thành dữ liệu gồm ít nhất 100 ảnh do nhóm tự chụp và ít nhất 30 ảnh có mặt nạ tay độc lập cho đánh giá phân đoạn. Bản thực nghiệm ban đầu đáp ứng phần dữ liệu công khai cho lúa; phần thu ảnh và xác nhận nhãn phải được thực hiện tại ruộng hoặc vườn. Các mục còn thiếu được liệt kê theo trạng thái, không thay bằng dữ liệu tổng hợp.

Có thể đăng ký mục tiêu định lượng như macro-F1 tối thiểu 0,80 trên tập test và IoU trung bình tối thiểu 0,50. Đây là mức kỳ vọng thiết kế cần thống nhất trước đánh giá, không phải chuẩn nông học hoặc cam kết hiệu năng ngoài đồng. Khi chưa có mask test thì chưa thể kết luận mục tiêu IoU đạt hay không.

Nhãn được quản lý theo cây. Ví dụ bạc lá thuộc lúa và gỉ sắt thuộc cà phê không tạo thành một taxonomy chung thiếu kiểm soát. Demo không tự suy cây từ ảnh; người dùng chọn cây để tải mô hình tương ứng. Nhãn lạ hoặc mô hình chưa có được hiển thị rõ.

1.4 Công trình liên quan và phạm vi

Prajapati và cộng sự nghiên cứu phân lớp bệnh lúa với xử lý ảnh và đặc trưng [2]. Mohanty và cộng sự chỉ ra tiềm năng CNN trên dữ liệu lá cây có kiểm soát [3]. Esgario và cộng sự kết hợp nhận dạng stress và ước lượng mức độ trên cà phê [4]. Những công trình này định hướng thiết kế, nhưng dùng dữ liệu và giao thức khác với lần chạy hiện tại.

Bảng 1.2 Vị trí của các hướng tiếp cận

Hướng	Ưu điểm	Giới hạn cần xét
Màu và hình thái	Dễ kiểm tra mask, chi phí thấp	Nhạy ánh sáng và nền xanh
Đặc trưng và k-NN	Dễ giải thích khoảng cách, ít tham số	Cần chuẩn hóa và dữ liệu đại diện
Đặc trưng và SVM	Biên quyết định phi tuyến	Phụ thuộc đặc trưng và C, gamma
CNN	Học biểu diễn từ dữ liệu	Cần kiểm tra chuyển miền, dữ liệu và tài nguyên

Đồ án chọn phương pháp truyền thống làm hệ thống chính để đáp ứng yêu cầu tự cài thuật toán lõi bằng NumPy. SVM dùng thư viện làm đối chiếu. CNN chỉ thuộc hướng phát triển; không mô tả CNN như một mô-đun đã hoàn thành.

Phạm vi hình học là phần lá nhìn thấy trong ảnh hai chiều. Không suy ra diện tích thật theo cm^2 khi chưa có thước chuẩn, không phục hồi mặt khuất và không đo mức độ toàn cây từ một lá. Lá cuộn, chồng lấp hoặc bị cắt khỏi ảnh có thể làm sai mẫu số của tỷ lệ. Cảnh báo biên hỗ trợ phát hiện một số trường hợp, nhưng không bao phủ tất cả.

Bệnh hỗn hợp, triệu chứng chưa rõ và cây ngoài taxonomy cần quy trình chuyên môn riêng. Cơ chế từ chối giúp giảm ép nhãn nhưng chưa được hiệu chuẩn bằng tập ảnh ngoài phân phối. Vì vậy kết quả phải được diễn giải cùng danh sách lớp đã học và điều kiện dữ liệu.

Chương 2 Cơ sở lý thuyết

2.1 Biểu diễn màu và chỉ số xanh

Ảnh sRGB mã hóa phi tuyến có các kênh R, G, B trong [0,255]. Tính toán được chuyển sang số thực trước khi trừ hoặc nhân để tránh tràn số uint8. HSV tách góc màu H, độ bão hòa S và độ sáng V; triển khai dùng H theo độ [0,360), S và V trong [0,1]. Quy ước này khác thang H 8 bit của OpenCV nên không so sánh trực tiếp các giá trị không đổi thang [5].

$$r = R/(R+G+B+\varepsilon),\ g = G/(R+G+B+\varepsilon),\ b = B/(R+G+B+\varepsilon);\ ExG = 2g-r-b \quad (2.1)$$

ε bảo vệ pixel đen. Vì r+g+b xấp xỉ 1, ExG dương thường gợi ý thành phần xanh trội. Ngưỡng ExG=0,04 và S>0,15 chọn seed xanh. Seed chỉ định hướng vùng lá; nếu dùng seed làm mask cuối, mô lá vàng hoặc hoại tử sẽ bị loại khỏi mẫu số, gây sai tỷ lệ tổn thương.

$$C = \max(R,G,B)-\min(R,G,B);\ V = \max(R,G,B);\ S = C/V \text{ khi } V>0 \quad (2.2)$$

Công thức HSV dùng RGB chuẩn hóa [0,1]; S=0 khi V=0. H tính theo kênh đạt cực đại và lấy modulo 360. Với pixel vô sắc C=0, H được đặt 0. Ngưỡng HSV mở rộng từ H=8 đến 170 độ, S>0,15 và V>0,06 để giữ các màu vàng/nâu có khả năng nối với phần xanh.

CIE Lab bắt đầu bằng tuyến tính hóa sRGB, nhân ma trận sang XYZ D65 và chuẩn hóa theo điểm trắng. Hàm f(t) dùng căn bậc ba khi $t>(6/29)^3$, nhánh tuyến tính ở vùng tối. $L^*=116f(Y/Yn)-16$; $a^*=500[f(X/Xn)-f(Y/Yn)]$; $b^*=200[f(Y/Yn)-f(Z/Zn)]$. L^* mô tả độ sáng, a^* trục xanh–đỏ, b^* trục xanh lam–vàng. Lab không làm ảnh bất biến chiếu sáng; nó chỉ thay cách biểu diễn khoảng cách màu.

2.2 Hình thái học và bảo toàn vùng lá

$$A \ominus B = \{x : Bx \subseteq A\};\ A \oplus B = \{x : Bx \cap A \neq \varnothing\} \quad (2.3)$$

$$A \circ B = (A \ominus B) \oplus B;\ A \bullet B = (A \oplus B) \ominus B \quad (2.4)$$

A là tập pixel ứng viên, B là phần tử cấu trúc vuông 3×3 và Bx là phần tử dịch tới x. Co yêu cầu mọi pixel lân cận đúng; giãn yêu cầu ít nhất một pixel đúng. Mở loại nhiễu nhỏ và làm đứt cầu hẹp; đóng nối khe nhỏ. Các phép toán dùng nền False ngoài ảnh. Quy ước biên phải thống nhất khi đối chiếu thư viện [5].

Kích thước phần tử cấu trúc càng lớn thì khử nhiễu mạnh hơn, đồng thời dễ loại lá hẹp và gộp vùng nền. Với lá lúa ở độ phân giải nhỏ, mở 5×5 có thể xóa phần lá mảnh. Vì vậy phiên bản mặc định dùng 3×3 và ghi cấu hình cùng mô hình. Khảo sát kích thước chỉ được điều chỉnh dựa trên train hoặc segval.

Sau hình thái học, thuật toán gán nhãn vùng liên thông 4 láng giềng bằng hàng đợi. Vùng có nhiều seed xanh nhất được giữ lại; nếu không có seed thì chọn vùng màu lớn nhất. Đây là giả định một lá chủ đạo, không phải thuật toán phân biệt từng lá trong tán. Nền cỏ xanh có thể thắng điểm seed và trở thành vùng sai.

Lấp lỗ gán nhãn nền, giữ nền nối với biên ảnh và đổi các thành phần nền kín thành lá. Thao tác này khôi phục các vùng bệnh nằm hoàn toàn trong lá mà ngưỡng màu đã bỏ qua. Nó không khôi phục được mô bệnh nối ra mép ngoài; sai số này cần xem trong đánh giá mask lá và sai số tỷ lệ.

Ví dụ mask 5×5 có khối vuông 3×3 ở giữa và pixel tâm rỗng: thành phần nền ở tâm không chạm biên nên được lấp; diện tích lá tăng từ 8 lên 9 pixel. Lấp lỗ là quyết định hình học, không gán nhãn bệnh cho pixel vừa được lấp. Bước K-means sẽ đánh giá màu của chúng sau đó.

2.3 K-means và dẫn xuất cập nhật tâm

$$J = \Sigma_j \Sigma_{x \in C_j} ||x - \mu_j||^2; \quad \mu_j = (1/|C_j|) \Sigma_{x \in C_j} x \quad (2.5)$$

Mỗi x là vector Lab của một pixel nằm trong mask lá, Cj là cụm j, μj là tâm và K là số cụm. K-means của Lloyd lặp hai bước gán điểm về tâm gần nhất và cập nhật tâm theo trung bình [6]. Chọn K quá nhỏ có thể trộn màu bệnh với mô khỏe; K quá lớn chia vỡ cùng loại mô và làm quy tắc chọn cụm không ổn định.

Giữ phân hoạch Cj cố định, đạo hàm của J theo μj bằng $2|C_j|\mu_j - 2\Sigma x$. Cho đạo hàm bằng 0 thu được trung bình cụm. Hessian bằng $2|C_j|I$ là xác định dương nếu cụm không rỗng, nên trung bình là cực tiểu duy nhất cho bước cập nhật. Với cụm rỗng, mã giữ tâm cũ để tránh chia cho 0.

Ở bước gán, từng điểm chọn tâm có bình phương khoảng cách nhỏ nhất nên J không tăng. Ở bước cập nhật, trung bình tối thiểu hóa J với phân hoạch hiện tại nên J cũng không tăng. J bị chặn dưới bởi 0, do đó dãy giá trị mục tiêu hội tụ. Kết quả này không chứng minh đạt tối ưu toàn cục; khởi tạo có thể đưa tới các nghiệm cục bộ khác nhau.

Triển khai dùng khởi tạo k-means++ và seed 42, tối đa 60 vòng, dừng khi thay đổi tâm lớn nhất dưới 10^{-6}. Nếu lá có quá nhiều pixel, chọn tối đa 8000 pixel bằng seed cố định để học tâm rồi gán toàn bộ pixel lá về các tâm đó. Thời gian giảm nhưng tâm vẫn là xấp xỉ của bài toán toàn ảnh.

ID cụm chỉ là chỉ số mảng, không có ý nghĩa mô khỏe hay bệnh. Sau phân cụm, chọn tâm có $a^* > -3$ và $b^* > 8$ hoặc $L^* < 30$ làm ứng viên tổn thương. Đây là heuristic màu cố định của baseline. Vùng vàng do ánh sáng hoặc vùng bóng có thể bị chọn nhầm; ngưỡng phải được kiểm định bằng nhãn tay.

2.4 Ví dụ số và tỷ lệ diện tích

Xét ảnh ma trận 4×4 trong Bảng 2.1, mỗi pixel có vector Lab=(L*,0,0) với L* lấy từ ô tương ứng. Chọn K=2 và tâm đầu L* bằng 0 và 8. Vì a*=b*=0 ở mọi điểm, khoảng cách Lab rút về khoảng cách một chiều trên L*. Đây là ví dụ tính tay minh họa thuật toán, không phải dữ liệu bệnh thật.

Bảng 2.1 Ví dụ tính tay K-means trên ảnh 4×4

Cột 1	Cột 2	Cột 3	Cột 4
0	0	8	8
0	2	8	10
0	2	8	10
2	2	10	10

Bước gán: các giá trị 0 có $d^2=(0,64)$, giá trị 2 có $d^2=(4,36)$, giá trị 8 có $d^2=(64,0)$, giá trị 10 có $d^2=(100,4)$. Vì vậy tám pixel ở hai cột trái thuộc cụm 1, tám pixel còn lại thuộc cụm 2. Bước cập nhật: $\mu_1=(4\times0+4\times2)/8=1$ và $\mu_2=(4\times8+4\times10)/8=9$. Gán lại không đổi; mỗi pixel lệch tâm một đơn vị nên SSE=16. Ví dụ đã kiểm chứng bằng NumPy trong tests/test_core.py. Phép đối chiếu K-means thư viện với cùng khởi tạo nằm trong scripts/verify_algorithms.py.

$$r = |D \cap L| / |L|; \text{ phần trăm tổn thương} = 100r \quad (2.6)$$

L là mask lá dự đoán, D là vùng nghi tổn thương dự đoán. Mã ràng buộc $D \subseteq L$ trước khi đếm, kiểm tra mask lá không rỗng và không dùng hình chữ nhật bao quanh lá làm mẫu số. Nếu |L|=1000 và |D|=120 thì r=0,12 tương ứng 12%, thuộc mức trung bình theo quy ước đồ án.

Quy ước mức độ gồm dưới 1% chưa thấy vùng nghi tổn thương đáng kể, từ 1% đến dưới 5% nhẹ, từ 5% đến dưới 20% trung bình, từ 20% trở lên nặng. Các ngưỡng này không thay thế thang bệnh đã được chuyên gia nông học chuẩn hóa. BRACOL dùng cách phân mức riêng [4]; không chuyển nhãn mức độ giữa hai hệ mà không hiệu chuẩn.

r là tỷ lệ trên diện tích chiếu của lá nhìn thấy. Lá cong hoặc ảnh xiên làm biến dạng diện tích chiếu không đồng đều. Sai số mask lá tác động trực tiếp mẫu số, nên cần báo cả IoU lá và sai số tuyệt đối của r, thay vì chỉ báo một con số phần trăm từ giao diện.

2.5 Đặc trưng kết cấu và phân lớp

$$LBP(x_c) = \Sigma_{p=0..7}\, 2^p\, [I(x_p) \geq I(x_c)] \quad (2.7)$$

LBP dùng 8 láng giềng vuông theo thứ tự Đông, Đông Bắc, Bắc, Tây Bắc, Tây, Tây Nam, Nam, Đông Nam. Số lần đổi bit trên vòng không quá 2 là mẫu uniform; gom theo số bit 1 thành 9 bin và một bin nonuniform. Chỉ lấy tâm có toàn bộ cửa sổ 3×3 nằm trong lá. Đây là biến thể vuông, khác LBP tròn có nội suy của Ojala và cộng sự [7].

Ví dụ tâm bằng 5, láng giềng theo thứ tự trên là [7,8,4,6,2,9,5,1]. Các bit là [1,1,0,1,0,1,1,0], mã bằng 1+2+8+32+64=107. Kiểm thử độc lập tính theo định nghĩa xác nhận kết quả. Không ép so bằng từng pixel với hàm thư viện khi hai định nghĩa lân cận khác nhau.

$$G(i,j) = \text{số cặp mức xám } (i,j) \text{ tại độ lệch } \delta;\ P = (G+G^T)/\Sigma(G+G^T) \quad (2.8)$$

GLCM lượng tử ảnh xám thành 16 mức, lấy các độ lệch (0,1), (1,0), (1,1), đối xứng và chuẩn hóa. Cả hai pixel của cặp phải thuộc lá. Từ P tính contrast, dissimilarity, homogeneity, ASM, energy và correlation rồi lấy trung bình ba hướng [8]. Cặp không tồn tại cho ma trận 0; correlation của phương sai bằng 0 quy ước bằng 1, cần xét cùng lượng thông tin của vùng.

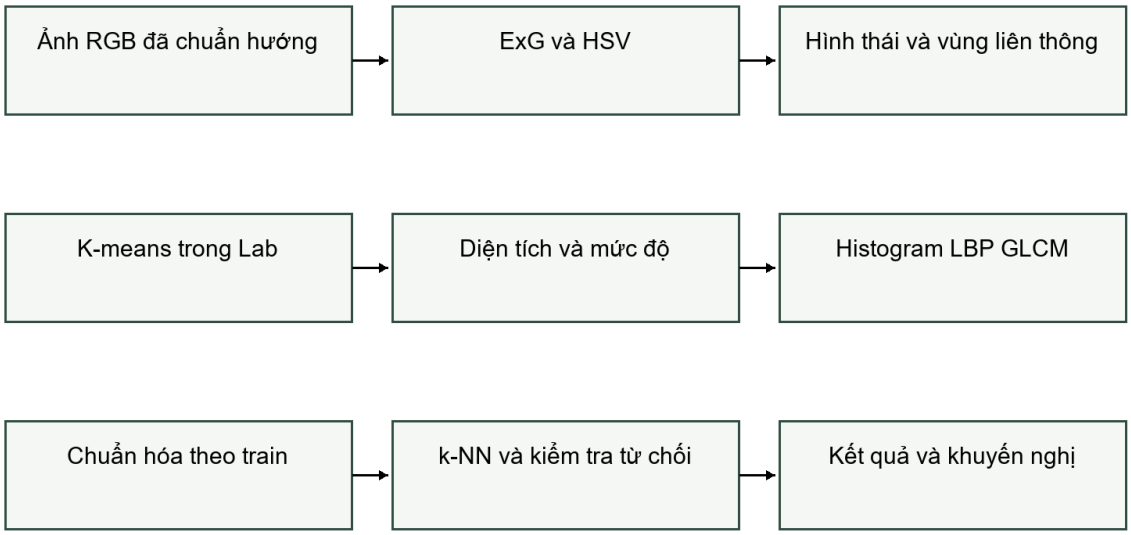
$$\text{contrast} = \Sigma(i-j)^2 P_{ij};\ \text{ASM} = \Sigma P_{ij}^2;\ \text{homogeneity} = \Sigma P_{ij}/[1+(i-j)^2] \quad (2.9)$$

Vector gồm 48 bin HSV, 6 moment Lab, 6 đặc trưng GLCM, 10 bin LBP và 4 trung bình xám theo góc phần tư, tổng 74 chiều. Chuẩn hóa $z=(x-m)/s$ với m,s chỉ học từ train; s rất nhỏ thay bằng 1. k-NN dùng khoảng cách Euclid và phiếu đồng đều. SVM RBF thư viện dùng C=1, gamma theo scale, class_weight balanced làm đối chiếu; nó không thay mã NumPy cốt lõi.

Chương 3 Thiết kế và cài đặt

3.1 Kiến trúc tổng thể

Hệ thống gồm một pipeline xác định nhận ảnh và cấu hình, một bộ phân lớp có trạng thái học từ train, một bộ đánh giá và giao diện. Hình 3 1 thể hiện thứ tự xử lý. Mặt nạ và đặc trưng được tạo cùng hàm process cho cả huấn luyện lẫn demo, giảm nguy cơ khác quy trình giữa hai giai đoạn.



Hình 3.1 Luồng phân tích một ảnh lá

Dữ liệu vào được chuẩn hướng EXIF bằng Pillow và giảm kích thước giữ nguyên tỷ lệ. Pillow phụ trách giải mã, đổi kích thước và xuất PNG; các phép chuyển màu, hình thái, phân cụm và đặc trưng nằm trong mã NumPy của dự án. Chỉ hàm đối chiếu và SVM baseline gọi thư viện chuyên dụng.

Đầu ra process gồm mask lá, mask ứng viên tổn thương, tâm Lab, đặc trưng, tỷ lệ, mức độ, cảnh báo và ảnh overlay. Bộ phân lớp nạp cấu hình đã lưu với mô hình, không dùng cấu hình khác khi demo. Đầu ra giao diện giữ nhãn dự đoán riêng với tỷ lệ diện tích, vì chúng trả lời hai câu hỏi khác nhau.

3.2 Thiết kế dữ liệu và hợp đồng mô đun

Bảng 3.1 Cấu trúc mã nguồn

Tệp	Trách nhiệm
src/algorithms.py	HSV, Lab, hình thái, vùng liên thông, K-means, LBP, GLCM
src/pipeline.py	Cấu hình, mask lá, mask tổn thương, đặc trưng và overlay
src/model.py	Chuẩn hóa, k-NN, từ chối và lưu NPZ
src/data.py	Đọc CSV, kiểm tra nguồn, nhóm và trùng byte
src/evaluation.py	Accuracy, macro-F1, confusion matrix, IoU và Dice
run_experiments.py	CV, test, stress và xuất bảng hình
app.py	Tải/chụp ảnh, xem kết quả, tải mặt nạ và JSON

Manifest là nguồn kiểm soát danh tính ảnh. Mỗi dòng có id, path, crop, label, domain, group, split, leaf_mask, lesion_mask, source và license. Đường dẫn tương đối tính từ gốc dự án; crop thuộc rice/coffee, domain thuộc plain/field. Các split train/test dành cho phân lớp, segval/segtest dành cho hiệu chỉnh và đánh giá phân đoạn.

group mô tả đơn vị thu thập độc lập, như một cây hoặc một phiên chụp. Bộ kiểm tra cấm một group đi qua nhiều split và cấm ảnh trùng SHA256. Quy tắc này phát hiện trùng byte, không phát hiện mọi ảnh chụp liên tiếp hoặc ảnh bị nén lại; hồ sơ thu thập và rà soát gần trùng vẫn cần thiết.

Mô hình lưu bằng NPZ chứa mảng số và chuỗi, mở với allow_pickle=False. Tệp có phiên bản schema, danh sách chiều đặc trưng, tham số chuẩn hóa, dữ liệu train chuẩn hóa, nhãn và cấu hình pipeline. Cách lưu này giúp đọc lại rõ ràng và tránh phụ thuộc đối tượng Python đã pickle.

3.3 Giả mã tách lá

Thuật toán 3 1 nhận ảnh RGB và ngưỡng đã cố định, trả về mask lá nhị phân hoặc lỗi có thông điệp cho người dùng. Phạm vi một lá chủ đạo được nêu trong giao diện và hướng dẫn chụp.

01 Đầu vào ảnh RGB, ngưỡng ExG, S, H, V và phần tử cấu trúc 3×3

02 Đổi ảnh sang float, tính màu chuẩn hóa r g b và HSV

03 Tạo seed từ ExG và độ bão hòa

04 Tạo ứng viên theo khoảng H, S và V để giữ cả mô vàng nâu

05 Mở rồi đóng mask ứng viên với nền False

06 Gán nhãn thành phần liên thông 4 láng giềng bằng hàng đợi

07 Đếm số seed trong từng thành phần, bỏ nhãn nền

08 Giữ thành phần có nhiều seed nhất hoặc lớn nhất nếu không có seed

09 Lấp thành phần nền kín bên trong vùng được giữ

10 Kiểm tra diện tích tối thiểu 40 pixel, trả mask hoặc báo lỗi

Thành phần nối seed được chọn thay vì giữ tất cả vùng màu nhằm hạn chế nhiễu và các vật nhỏ. Lấp lỗ sau chọn thành phần giúp đưa màu hoại tử kín trong lá trở lại vùng xử lý. Tuy nhiên thao tác có thể lấp cả lỗ thủng thật; đây là giả định hình học cần được đối chiếu với cách người gán nhãn định nghĩa diện tích lá.

Nếu lá gần hết xanh hoặc nền tương tự lá, lựa chọn theo seed có thể sai. Phiên bản baseline không tự chuyển sang mô hình học sâu khi thất bại; nó hiển thị lỗi hoặc cảnh báo để người dùng chụp lại. Một lỗi im lặng trả về toàn ảnh sẽ làm tỷ lệ diện tích có vẻ hợp lệ nhưng sai ý nghĩa, nên mã kiểm tra mặt nạ quá nhỏ và cảnh báo diện tích bất thường.

Không mở mask tổn thương bằng phần tử 3×3 theo mặc định vì thao tác có thể xóa đốm bệnh nhỏ. Hình thái học trong pipeline tập trung vào mask lá. Nếu bổ sung lọc đốm, phải khảo sát ảnh hưởng tới recall của tổn thương nhỏ trên segval và ghi rõ thay đổi.

3.4 Giả mã K-means và chọn vùng tổn thương

01 Đầu vào ảnh RGB, mask lá L và K=3

02 Chuyển toàn ảnh sang Lab, lấy X gồm pixel thuộc L

03 Lấy mẫu tối đa 8000 pixel bằng seed 42

04 Khởi tạo K tâm theo xác suất khoảng cách bình phương

05 Lặp gán mỗi điểm mẫu về tâm gần nhất

06 Cập nhật tâm bằng trung bình, giữ tâm cũ nếu cụm rỗng

07 Dừng khi tâm thay đổi $<10^{-6}$ hoặc đủ 60 vòng

08 Gán toàn bộ pixel lá về các tâm đã học

09 Chọn tâm vàng nâu hoặc tối theo quy tắc Lab cố định

10 Tạo D và ràng buộc D là tập con của L, trả D và các tâm

Khởi tạo k-means++ ưu tiên điểm xa các tâm đã chọn. Khi mọi điểm giống nhau, tổng trọng số bằng 0; mã chọn điểm đầu để tránh phép chia không xác định. K không vượt số điểm mẫu. Cụm rỗng không được cập nhật bằng trung bình của mảng rỗng, nhờ đó tâm luôn hữu hạn.

Quy tắc chọn tâm dùng cả màu và độ sáng để tạo ứng viên. Nó không học từ nhãn bệnh và không đảm bảo mỗi cụm ứng với một mô sinh học. Khi toàn lá chuyển vàng, nhiều hoặc tất cả cụm có thể được chọn. Khi bóng đổ nằm trong lá, cụm tối có thể thành dương tính giả. Các tình huống này cần nhãn pixel để đo.

Mask tự động không được dùng làm ground truth cho cùng thuật toán. Công cụ đa giác cung cấp đường đi độc lập để con người tạo nhãn. Tập segval dùng khảo sát K, ngưỡng tâm và phần tử cấu trúc; segtest khóa trước để đánh giá IoU cuối cùng. Khi chưa có segtest, báo cáo giữ trạng thái chưa đo thay vì mặc định thuật toán phân đoạn đúng.

3.5 Trích đặc trưng và huấn luyện

01 Đầu vào ảnh, mask lá và nhãn đã xác nhận trong manifest

02 Tạo histogram HSV 16 bin mỗi kênh chỉ từ pixel lá

03 Tính trung bình và độ lệch chuẩn của ba kênh Lab

04 Chuyển xám, tạo GLCM có mask ở ba hướng và lấy 6 thuộc tính

05 Tính LBP vuông, chỉ giữ tâm có đủ 3×3 trong mask lá

06 Gom LBP uniform thành 10 bin và lấy bốn trung bình xám theo vùng

07 Ghép vector 74 chiều, kiểm tra mọi giá trị hữu hạn

08 Trong mỗi fold train, fit chuẩn hóa và k-NN trên phần train của fold

09 Chọn k và nhóm đặc trưng theo macro-F1 validation trung bình

10 Fit lại trên toàn train, lưu model, đánh giá test đúng một giao thức

Các nhóm đặc trưng khảo sát là màu gồm 54 chiều đầu, kết cấu gồm 6 GLCM và 10 LBP, toàn bộ gồm 74 chiều kể cả 4 trung bình vùng. Mỗi cấu hình dùng cùng folds để giảm nhiễu do cách chia. k thuộc {1,3,5,7}; trường hợp số mẫu train nhỏ hơn k thì mã lấy số láng giềng có sẵn và ghi rõ dữ liệu cần đủ lớn.

Chuẩn hóa nằm trong từng lần fit của mô hình, nên thống kê validation không đi vào scaler. SVM đối chiếu dùng pipeline StandardScaler và SVC theo đúng nguyên tắc này. Không dùng test để chọn ngưỡng ExG, kích thước ảnh hoặc k sau khi thấy kết quả. Nếu sửa phương pháp dựa vào lỗi test, cần một test độc lập mới cho kết luận cuối.

Cơ chế từ chối dựa trên tỷ lệ phiếu thấp hơn 0,6 hoặc khoảng cách gần nhất vượt 1,5 lần phân vị 95% khoảng cách láng giềng gần nhất giữa các mẫu train. Đây là heuristic để trình diễn khả năng không ép nhãn; chưa có tập ngoài phân phối để hiệu chuẩn độ nhạy từ chối.

3.6 Độ phức tạp và xử lý số

Bảng 3.2 Chi phí tính toán

Khối xử lý	Thời gian	Bộ nhớ chính
Đổi màu và ngưỡng	$O(P)$	$O(P)$
Hình thái phần tử $s \times s$	$O(Ps^2)$	$O(Ps^2)$ dạng view và phép giảm
Vùng liên thông và lấp lỗ	$O(P)$	$O(P)$
K-means mẫu Q điểm	$O(TQK)$ với 3 chiều màu	$O(QK)$
Gán toàn bộ pixel lá	$O(PK)$	$O(PK)$
Histogram LBP GLCM	$O(P+g^2)$	$O(P+g^2)$
k-NN một truy vấn	$O(nd+n \log n)$	$O(nd)$ dữ liệu train

$P=M \times N$, $Q \leq 8000$, $T \leq 60$, $g=16$ là số mức xám, n là số ảnh train và $d \leq 74$. Vì K nhỏ và cố định, đổi màu và vùng liên thông thường chiếm tỷ trọng đáng kể ở ảnh nhỏ. Chi phí chính xác phụ thuộc cách vector hóa, không thể suy trực tiếp thời gian chạy chỉ từ ký hiệu O.

Mảng sliding_window_view biểu diễn cửa sổ bằng view để tránh sao chép toàn bộ cửa sổ; phép all/any vẫn thực hiện số phép toán tỷ lệ s^2. Vùng liên thông dùng hàng đợi tránh đệ quy sâu. Giới hạn cạnh dài giúp giữ chi phí ổn định giữa ảnh điện thoại có độ phân giải khác nhau, đồng thời có thể làm mất đốm rất nhỏ.

Để ước lượng bán kính từ chối, khoảng cách train–train được tính bằng $||a||^2+||b||^2-2a^Tb$. Công thức tránh tensor $n \times n \times d$; sai số dấu âm rất nhỏ được chặn về 0 trước căn bậc hai. Bộ nhớ vẫn $O(n^2)$ cho ma trận khoảng cách, nên với tập rất lớn cần xử lý theo khối hoặc mô hình láng giềng phù hợp hơn.

Các phép trừ kênh màu dùng float64 để tránh modulo của uint8. Chuẩn hóa histogram dùng tổng ít nhất 1 để tránh chia 0; cấu hình và kiểm tra ảnh giữ đặc trưng hữu hạn. Mask lưu 0/255 khi xuất PNG, trong tính toán dùng bool. Sự khác biệt giữa 0/1 và 0/255 cần được chuẩn hóa trước đánh giá.

3.7 Kiểm chứng và giao diện demo

Bảng 3.3 Sai số đối chiếu cùng quy ước

Phép toán	Max abs	MSE
HSV	1.137e-13	1.305e-28
Lab D65	4.704e-03	3.221e-06
erode	0.000e+00	0.000e+00
dilate	0.000e+00	0.000e+00
GLCM	0.000e+00	0.000e+00
GLCM properties	1.388e-17	3.210e-35
K-means centers same init	1.332e-15	5.812e-31
K-means SSE	2.220e-16	4.930e-32
k-NN predictions	0.000e+00	0.000e+00
LBP hand example	0.000e+00	0.000e+00

Bảng 3.3 lấy trực tiếp từ verification.json. HSV và Lab so với scikit-image [11]; co/giãn so với OpenCV có nền biên 0 [13]; GLCM và thuộc tính so với scikit-image; K-means so cùng tâm đầu với sklearn [12]. Lab có sai khác nhỏ do hằng số chuyển màu và điểm trắng. K-means có sai số dấu chấm động ở mức rất nhỏ.

LBP được kiểm chứng bằng định nghĩa lân cận vuông và ví dụ 107. Không gọi khác biệt nội suy với LBP tròn của thư viện là sai số cài đặt. Kiểm thử hành vi còn kiểm tra cụm rỗng, mask rỗng, mask tổn thương là tập con của lá, rò rỉ group và model lưu–nạp.

Demo hiển thị ảnh gốc, mask lá, overlay và tham số. Camera dùng st.camera_input [14], phụ thuộc quyền trình duyệt và ngữ cảnh truy cập an toàn. Khi chưa có mô hình cà phê, demo vẫn chạy phân đoạn và ghi rõ chưa phân lớp. Khi UCI chưa có lá khỏe, giao diện hiển thị danh sách lớp và giới hạn này.

Chương 4 Thực nghiệm và đánh giá

4.1 Môi trường và dữ liệu công khai

Lần chạy dùng Windows-11-10.0.26200-SP0, Python 3.12.14, CPU nhận diện Intel64 Family 6 Model 151 Stepping 2, GenuineIntel. Các phép xử lý và mô hình chạy trên CPU. Tệp environment.json lưu môi trường; thông số RAM và tên CPU thương mại cần đối chiếu máy khi nhóm nộp, không suy từ chuỗi nhận diện thành một cấu hình cụ thể.

Bảng 4.1 Phiên bản thư viện đã dùng

Thư viện	Phiên bản
numpy	2.5.4
Pillow	12.3.0
opencv-python-headless	4.14.0.94
scikit-image	0.26.0
scikit-learn	1.8.0
streamlit	1.66.1
matplotlib	3.11.2

Rice Leaf Diseases tại UCI gồm 120 ảnh, ba lớp cân bằng, mỗi lớp 40 ảnh; lá được chụp trên nền trắng dưới ánh sáng trực tiếp. Nguồn dùng giấy phép CC BY 4.0 và có DOI định danh [9]. Bản tải được ghi URL, SHA256 và số ảnh trong rice_provenance.json. Đây là tập nhỏ phù hợp baseline, chưa đại diện ruộng lúa Việt Nam.

Bảng 4.2 Phân bố dữ liệu lúa

Lớp	Train	Test	Tổng
Bacterial leaf blight	30	10	40
Brown spot	30	10	40
Leaf smut	30	10	40
Toàn bộ	90	30	120

Không có lớp healthy trong bộ này. Vì vậy accuracy ở Chương 4 là phân biệt ba bệnh đã biết, không phải độ chính xác phân biệt cây khỏe và bệnh. Mask vết bệnh không được cung cấp trong bản tải; chưa có cơ sở tính IoU với nhãn tay.

4.2 Giao thức chia tập và chỉ số

Script tải xếp thứ tự file và dùng seed 42 chọn 10 ảnh mỗi lớp làm test, 30 ảnh còn lại làm train. Vì dữ liệu nguồn không có định danh cây/phiên, group ban đầu bằng id ảnh. Cách chia có phân tầng theo lớp nhưng độc lập ở cấp cây chưa được chứng minh. Đây là giới hạn quan trọng khi diễn giải kết quả 90%.

Bên trong 90 ảnh train, StratifiedGroupKFold tạo 5 fold, không cho group đi qua train/validation [12]. Cấu hình k-NN được chọn theo macro-F1 trung bình của 12 tổ hợp k và tập đặc trưng. Scaler chỉ fit trong phần train của fold. Cấu hình phân đoạn K=3 và ngưỡng màu là baseline cố định, chưa tối ưu bằng segtest.

$$\text{accuracy} = \text{số dự đoán đúng}/n;\ F1_c = 2TP_c/(2TP_c+FP_c+FN_c) \quad (4.1)$$

$$\text{macro } F1 = (1/C)\Sigma_c F1_c;\ IoU = |D \cap G|/|D \cup G| \quad (4.2)$$

$$Dice = 2|D \cap G|/(|D|+|G|);\ \text{MAE tỷ lệ} = (1/n)\Sigma|\hat{r}_i - r_i| \quad (4.3)$$

C là số lớp cố định, G là mask ground truth. F1 bằng 0 nếu mẫu số bằng 0. Với hai mask rỗng, IoU/Dice quy ước 1; nếu chỉ một mask rỗng thì bằng 0. Khi có nhãn tay, cần báo số ảnh GT rỗng và kết quả trên nhóm có tổn thương để tránh trung bình bị chi phối bởi ảnh khỏe.

Mean và độ lệch chuẩn CV mô tả biến thiên giữa folds, không phải khoảng tin cậy độc lập. Test chỉ có một tập 30 ảnh nên báo một giá trị cùng cỡ mẫu và confusion matrix; không gán thêm ±SD giả từ một lần chạy. Thời gian báo trung bình ±SD theo ảnh, gồm giải mã, resize và xử lý pipeline, chưa tính thời gian mạng hoặc người dùng thao tác.

4.3 So sánh k-NN và SVM

Bảng 4.3 Kết quả phân lớp trên cùng dữ liệu

Mô hình	Macro-F1 CV	Accuracy test	Macro-F1 test
k-NN NumPy	0.8144 ± 0.1456	**90.0%**	**0.9019**
SVM RBF	**0.8551 ± 0.1839**	**90.0%**	0.8995

Hai mô hình đều dự đoán đúng 27/30 ảnh test. Macro-F1 khác nhẹ do phân bố lỗi theo lớp. k-NN được triển khai làm mô hình chính để đáp ứng yêu cầu tự cài, còn SVM dùng làm đối chiếu với cùng vector và train/test. Bảng 4 3 không cho thấy bằng chứng đủ mạnh rằng một mô hình vượt trội tổng quát.

SVM có macro-F1 CV trung bình cao hơn trong lần chia này nhưng độ lệch chuẩn giữa folds cũng lớn. k-NN toàn bộ đặc trưng với k=3 được chọn trong không gian cấu hình của k-NN; không dùng điểm test để đổi sang một k khác. So sánh công bằng hơn cần nhiều nhóm thu thập độc lập và kiểm định trên các nhóm đó.

Accuracy 90% trên 30 mẫu chỉ tương ứng ba lỗi; một ảnh đổi nhãn làm accuracy thay đổi 3,33 điểm phần trăm. Do đó chênh lệch nhỏ của macro-F1 không nên được mô tả là cải tiến chắc chắn. Khoảng bất định do lấy mẫu, nguồn ảnh và nguy cơ ảnh gần trùng đều cần được xét.

Cơ chế từ chối giữ lại 93.3% ảnh test; accuracy trên phần được giữ là 96.4%. Kết quả này có mẫu số khác accuracy 90% trên toàn tập. Không thay giá trị toàn tập bằng giá trị trên nhóm đã chọn để làm báo cáo đẹp hơn. Coverage và độ chính xác có điều kiện cần được trình bày cùng nhau.

Các công trình [2]–[4] có thể dùng đặc trưng, dữ liệu và split khác. Báo cáo không lấy con số công bố làm đường chuẩn trực tiếp rồi kết luận phương pháp mới tốt hơn. Muốn tái hiện cần cùng tập ảnh, preprocessing, nhãn, quy trình chọn tham số và cách tính chỉ số.

4.4 Khảo sát k và nhóm đặc trưng

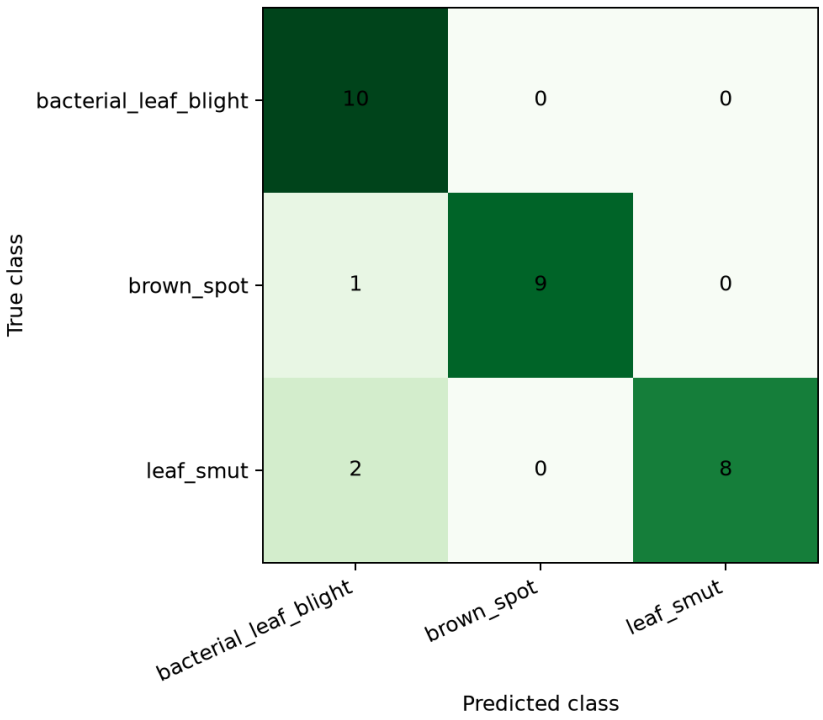
Bảng 4.4 Macro-F1 năm fold theo cấu hình

Đặc trưng	k	Trung bình	Độ lệch chuẩn
Màu 54	1	0.8064	0.1186
Màu 54	3	0.7435	0.0940
Màu 54	5	0.7655	0.1733
Màu 54	7	0.7436	0.1444
Kết cấu 16	1	0.6894	0.1440
Kết cấu 16	3	0.6783	0.1370
Kết cấu 16	5	0.6807	0.0659
Kết cấu 16	7	0.6613	0.1503
Toàn bộ 74	1	0.8084	0.1276
Toàn bộ 74	3	**0.8144**	0.1456
Toàn bộ 74	5	0.7786	0.1276
Toàn bộ 74	7	0.7904	0.1158

Cấu hình tốt nhất trong lưới k-NN là toàn bộ 74 chiều với k=3. Khi k tăng, mô hình giảm nhạy với một láng giềng riêng lẻ nhưng có thể trộn các lớp có màu gần nhau. Kết cấu đơn lẻ thiếu thông tin màu tổn thương, nên hiệu quả không nhất thiết tăng khi bỏ màu khỏi vector.

Đây là khảo sát trên validation trong train, không phải 12 lần đo test rồi chọn kết quả cao nhất. Cùng một bộ folds được dùng cho mọi cấu hình. Các fold có kích thước nhỏ làm độ lệch chuẩn đáng kể; kết quả lựa chọn cần xác nhận lại trên dữ liệu thu thập độc lập khi mở rộng.

4.5 Ma trận nhầm lẫn và phân tích lỗi



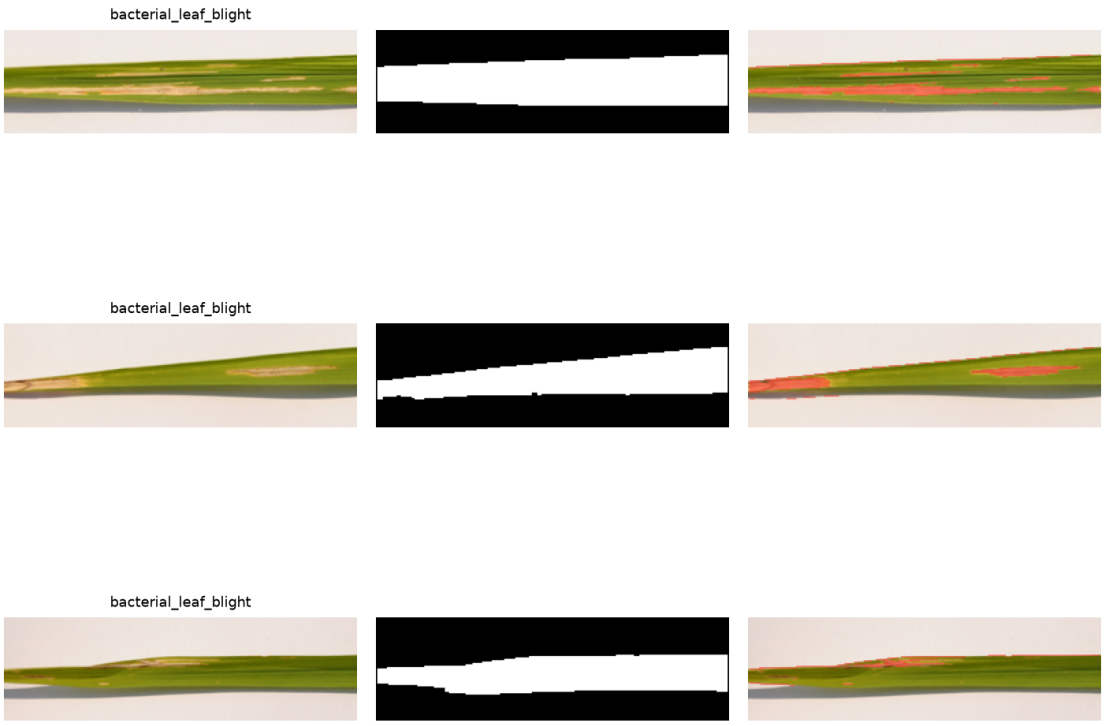
Hình 4.1 Ma trận nhầm lẫn k-NN trên 30 ảnh test

Hình 4.1 cho thấy ba lỗi đều được dự đoán thành bạc lá: một ảnh đốm nâu và hai ảnh leaf smut. Lớp bạc lá có recall 10/10 nhưng precision 10/13. Một lớp có recall cao không có nghĩa nhận dạng tốt về mọi mặt; cần đọc cả hàng và cột của ma trận.

Giả thuyết kỹ thuật là một số lá có màu vàng/khô toàn cục gần nhóm bạc lá trong không gian đặc trưng. Để kiểm tra, nhóm cần mở các id sai trong predictions.csv, so vùng lá, histogram, mask và láng giềng gần nhất. Báo cáo không khẳng định nguyên nhân sinh học chỉ dựa vào vị trí ô nhầm lẫn.

Tỷ lệ mặt nạ nghi tổn thương lớn không bảo đảm phân lớp đúng. Bộ phân lớp dùng màu và kết cấu toàn lá, nên có thể đúng nhãn dù mask tổn thương sai, hoặc ngược lại. Đánh giá phân lớp và phân đoạn phải độc lập về chỉ số, nhưng cùng truy về ảnh gốc để hiểu lan truyền sai số.

4.6 Quan sát các bước xử lý



Hình 4.2 Ba ảnh test cùng mask lá và overlay ứng viên tổn thương

Mỗi hàng của Hình 4 2 gồm ảnh đầu vào, mask lá và vùng tô đỏ theo quy tắc Lab. Các hình lấy từ lần chạy thật trên UCI, không phải ảnh thực địa hoặc nhãn tay. Kích thước từng cột được giữ thống nhất để quan sát vùng biên và phần mô vàng/nâu.

Cần kiểm tra mask có bỏ mất đầu lá, giữ cả nền hoặc lấp lỗ không hợp lý hay không. Overlay chỉ là dự đoán của thuật toán. Mắt người có thể nhận xét sơ bộ nhưng không thay thế phép so với ground truth độc lập. Việc chọn ảnh minh họa không được dùng thay bảng số trên toàn tập.

4.7 Ảnh hưởng độ sáng và thời gian

Bảng 4.5 Kiểm tra stress độ sáng không huấn luyện lại

Điều kiện	n	Accuracy	Macro-F1	Lỗi tách lá
Ảnh gốc	30	90.0%	0.9019	0
Nhân RGB 0.6	30	36.7%	0.2412	0
Nhân RGB 1.4	30	50.0%	0.4500	0

Cả hai phép biến đổi đều làm giảm hiệu năng đáng kể. Nhân RGB 0,6 làm phần lớn ảnh dịch trong các bin V, L* và moment; nhân 1,4 còn gây cắt ngưỡng các kênh ở 255. Dù chuẩn hóa đặc trưng theo train, ảnh test đã lệch phân phối nên khoảng cách k-NN thay đổi. LBP có thể bền với biến đổi đơn điệu nhưng vector kết hợp vẫn chứa nhiều thành phần nhạy sáng.

Các ảnh sau nhân độ sáng là biến thể tổng hợp của cùng test, không phải mẫu độc lập mới và không phải ảnh ngoài đồng. Không gộp chúng vào số ảnh tự chụp. Không có lỗi tách lá bị ném ra trong lần stress này, nhưng việc hàm trả được mask không chứng minh mask chính xác; vẫn cần ground truth để đánh giá.

Thời gian giải mã và xử lý trung bình là 129.0 ± 39.3 ms/ảnh trên 120 ảnh. Phép đo gồm đọc ảnh, resize, phân đoạn và trích đặc trưng; không gồm thời gian người dùng, truyền ảnh và render giao diện. Đây là thời gian của máy chạy hiện tại, không phải benchmark trên điện thoại.

Hướng cải thiện có thể gồm chuẩn hóa chiếu sáng có kiểm chứng, giảm trọng số đặc trưng độ sáng hoặc tăng cường ánh sáng chỉ trong train. Mỗi thay đổi cần khảo sát bằng validation và đánh giá lại test mới nếu đã dùng test hiện tại để thiết kế. Không tự áp dụng điều chỉnh rồi chỉ giữ lại kết quả tăng.

4.8 Giao thức IoU và chuyển miền ngoài đồng

Bảng 4.6 Trạng thái dữ liệu cần bổ sung

Yêu cầu	Hiện có	Trạng thái
Ảnh tự chụp tại ruộng/vườn	0	Chưa hoàn thành
Ảnh segtest gán nhãn tay	0	Chưa đo IoU
Test phân lớp ngoài đồng	0	Chưa có kết quả
Thực nghiệm cây cà phê	0	Cần nhập dữ liệu

Cần lấy ít nhất 30 ảnh segtest độc lập với tập điều chỉnh phân đoạn. Mỗi ảnh có hai mask tay cùng kích thước gốc: phần lá nhìn thấy và vùng tổn thương. Ít nhất hai người kiểm tra một phần ảnh, thống nhất vùng mép và vùng nghi ngờ trước đánh giá. Nếu chỉ có 30 ảnh đã dùng để chỉnh ngưỡng, không gọi đó là test độc lập.

Script đánh giá mask dùng nội suy nearest khi đưa về kích thước xử lý. IoU tổn thương tính trên toàn ảnh, vì nếu mask lá bỏ mất một vết thì đó vẫn là lỗi end-to-end. Đồng thời đo IoU lá, Dice và sai số tỷ lệ. Mask GT tổn thương ngoài GT lá bị từ chối thay vì tự sửa âm thầm.

So sánh miền cần cùng mô hình và danh sách lớp cố định cho ảnh nền trơn và ảnh ngoài đồng. Báo số ảnh và phân bố lớp từng miền, macro-F1, accuracy và số lỗi tách lá. group phải theo cây/phiên; không đưa các crop của cùng lá qua hai split. Nếu một miền thiếu lớp, nêu rõ ảnh hưởng tới macro-F1 và giới hạn so sánh.

BRACOL có 1747 ảnh toàn lá và giấy phép CC BY 4.0 [10]. Cần nhập đúng metadata nhãn và giữ các mẫu cùng lá trong một nhóm. Mức độ nguồn có liên quan mask tự động; chúng không thay nhãn tay độc lập của bài toán này. Hiện mã đã hỗ trợ mô hình cà phê riêng, nhưng báo cáo không đưa số đo cà phê khi chưa chạy trên dữ liệu tương ứng.

Chương 5 Kết luận và hướng phát triển

5.1 Đối chiếu mục tiêu

Bảng 5.1 Kết quả so với mục tiêu

Mục tiêu	Kết quả hoặc minh chứng	Đánh giá
Pipeline 5 chức năng	NumPy, mask, diện tích, đặc trưng, demo	Có mã thực thi
Kiểm chứng thuật toán	10 phép đối chiếu đạt dung sai định trước	Đạt baseline
Phân lớp bệnh lúa	27/30 đúng, macro-F1 0.9019	Đạt trên test UCI
Phân lớp bệnh cà phê	Hợp đồng dữ liệu và model riêng đã có	Chưa thực nghiệm
IoU trên ≥30 ảnh tay	Chưa có mask segtest	Chưa đạt dữ liệu
≥100 ảnh tự chụp	Chưa có nhật ký thực địa	Chưa đạt dữ liệu

Hệ thống đã tạo mốc thực nghiệm có thể tái lập bằng một lệnh và giao diện có thể quan sát từng bước. Thuật toán tự cài được kiểm chứng ở các phép có quy ước tương ứng. Điều này xác nhận một phần tính đúng của triển khai, không đồng nghĩa tính đúng của mọi mask hoặc khả năng chẩn đoán ngoài phân phối.

Kết quả công khai khả quan nhưng điều kiện thu ảnh có kiểm soát và cỡ test nhỏ hạn chế sức mạnh kết luận. Phép stress độ sáng bộc lộ độ nhạy rõ rệt. Trước khi dùng ngoài đồng, cần hoàn thiện dữ liệu tự chụp, thêm lớp khỏe và kiểm tra phân đoạn bằng nhãn tay độc lập.

Giới hạn chính gồm giả định một lá, nền màu gần lá, mô hoại tử nối mép, lá cong và bệnh hỗn hợp. Khoảng cách và phiếu k-NN không phải xác suất đã hiệu chuẩn. Ngưỡng mức độ chỉ là quy ước của đồ án, chưa liên kết với thiệt hại sinh lý hoặc ngưỡng can thiệp nông học.

5.2 Hướng phát triển và kế hoạch kiểm chứng

Hướng thứ nhất là kiểm soát chuyển miền và chiếu sáng. Thu thêm ảnh theo máy, giống, địa điểm và thời điểm; tách test theo cây và phiên. So sánh đặc trưng hiện tại với chuẩn hóa ánh sáng trên train/segval, báo cả hiệu năng và tỷ lệ từ chối theo miền. Đặt lại ngưỡng mức độ dựa trên đồng thuận chuyên gia và sai số diện tích.

Hướng thứ hai là MobileNetV3 hoặc một CNN gọn chạy bằng TensorFlow Lite trên điện thoại. Dùng cùng bộ test đã khóa để so với baseline, đo dung lượng mô hình, thời gian suy luận, macro-F1 và hiệu năng ngoài đồng. Lượng tử hóa int8 chỉ được chấp nhận sau khi kiểm tra suy giảm; mục tiêu offline cần thử thực tế khi thiết bị không có mạng.

Hướng thứ ba là liên kết ảnh với tọa độ GPS và thời điểm có sự đồng ý của người thu thập. Dữ liệu bệnh lá và dữ liệu stress vệ tinh cần chuẩn hóa độ phân giải không gian, khoảng thời gian và độ không chắc chắn. Chưa thể coi một điểm lá bệnh là đại diện cả pixel vệ tinh hoặc suy ra tác nhân bệnh từ chỉ số stress chung.

Bước hoàn thiện trước bảo vệ là bổ sung đủ dữ liệu thật và chạy lại toàn bộ chương thực nghiệm. Thứ tự nên là khóa taxonomy, xác nhận nhãn, chia nhóm, gán mask, chọn tham số trên validation, khóa cấu hình rồi đánh giá. Sau đó cập nhật báo cáo, slide và video bằng đúng số liệu của lần chạy cuối.

Mã nguồn, manifest, cấu hình, phiên bản thư viện và kết quả từng ảnh cần được gắn cùng phiên bản repo. Khi thay dữ liệu, phải xem lại các kết luận chứ không chỉ thay bảng số. Công việc nhóm và việc sử dụng công cụ AI được khai báo bằng hồ sơ thật trong phụ lục, giữ trách nhiệm giải thích ở từng thành viên.

Tài liệu tham khảo

[1] NASA Space Apps, Field Shift Adapting Farms with NASA Data, 2026. https://www.spaceappschallenge.org/2026/challenges/field-shift-adapting-farms-with-nasa-data/. Truy cập 05/11/2026.

[2] H. B. Prajapati, J. P. Shah, V. K. Dabhi, "Detection and classification of rice plant diseases," Intelligent Decision Technologies, vol. 11, no. 3, pp. 357–373, 2017. DOI 10.3233/IDT-170301.

[3] S. P. Mohanty, D. P. Hughes, M. Salathé, "Using Deep Learning for Image-Based Plant Disease Detection," Frontiers in Plant Science, vol. 7, 1419, 2016. DOI 10.3389/fpls.2016.01419.

[4] J. G. M. Esgario, R. A. Krohling, J. A. Ventura, "Deep learning for classification and severity estimation of coffee leaf biotic stress," Computers and Electronics in Agriculture, vol. 169, 105162, 2020. DOI 10.1016/j.compag.2019.105162. Bản tác giả arxiv.org/abs/1907.11561.

[5] R. C. Gonzalez, R. E. Woods, Digital Image Processing, 4th ed. Pearson, 2018.

[6] S. P. Lloyd, "Least Squares Quantization in PCM," IEEE Transactions on Information Theory, vol. 28, no. 2, pp. 129–137, 1982. DOI 10.1109/TIT.1982.1056489.

[7] T. Ojala, M. Pietikäinen, T. Mäenpää, "Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns," IEEE TPAMI, vol. 24, no. 7, pp. 971–987, 2002. DOI 10.1109/TPAMI.2002.1017623.

[8] R. M. Haralick, K. Shanmugam, I. Dinstein, "Textural Features for Image Classification," IEEE Transactions on Systems, Man, and Cybernetics, vol. SMC-3, no. 6, pp. 610–621, 1973. DOI 10.1109/TSMC.1973.4309314.

Tài liệu tham khảo về dữ liệu và thư viện

[9] J. Shah, H. Prajapati, V. Dabhi, Rice Leaf Diseases, UCI Machine Learning Repository. DOI 10.24432/C5R013. CC BY 4.0. archive.ics.uci.edu/dataset/486/rice+leaf+diseases.

[10] R. A. Krohling, J. G. M. Esgario, J. A. Ventura, BRACOL, Mendeley Data, v1, 2019. DOI 10.17632/yy2k5y8mxg.1. CC BY 4.0. data.mendeley.com/datasets/yy2k5y8mxg/1.

[11] scikit-image developers, Color and Feature API, scikit-image documentation. scikit-image.org/docs/stable/api/skimage.color.html và skimage.feature.html. Truy cập 05/11/2026.

[12] scikit-learn developers, StratifiedGroupKFold, KMeans, SVC API, scikit-learn documentation. scikit-learn.org/stable/modules/classes.html. Truy cập 05/11/2026.

[13] OpenCV developers, Eroding and Dilating, OpenCV 4 documentation. docs.opencv.org/4.x/db/df6/tutorial_erosion_dilatation.html. Truy cập 05/11/2026.

[14] Streamlit developers, st.camera_input API. docs.streamlit.io/develop/api-reference/widgets/st.camera_input. Truy cập 05/11/2026.

Các tài liệu học thuật cung cấp cơ sở phương pháp; các trang API phục vụ kiểm chứng triển khai và tái lập môi trường. Số liệu trong Chương 4 chỉ lấy từ tệp kết quả của dự án. Không sao chép chỉ số của công trình tham khảo thành kết quả của nhóm.

Phụ lục Hướng dẫn chạy và minh chứng

Liên kết repo GitHub của nhóm [Nhóm điền URL thật sau khi tạo repo]. Mã nguồn đầy đủ và hướng dẫn chi tiết được giữ trong repo; thân báo cáo dùng giả mã để giải thích thuật toán.

A Cài đặt và tái lập

python -m venv .venv

.venv\Scripts\python.exe -m pip install -r requirements-lock.txt

.venv\Scripts\python.exe scripts/download_rice.py

.venv\Scripts\python.exe run_experiments.py

.venv\Scripts\python.exe -m streamlit run app.py

.venv\Scripts\python.exe -m pytest -q

Một lệnh run_experiments.py tái tạo kết quả phân lớp, kiểm chứng, stress độ sáng và đánh giá mask khi manifest có nhãn. Tải dữ liệu là bước chuẩn bị riêng cần Internet. Demo chạy offline sau khi có thư viện, dữ liệu mẫu và model. Đường dẫn thực thi tính từ gốc dự án.

B Ví dụ số và kiểm chứng

K-means trên ảnh 4×4 và LBP 107 được kiểm tra trong tests/test_core.py. Bảng đối chiếu thư viện xuất bởi scripts/verify_algorithms.py. Kết quả từng ảnh ở results/predictions.csv; folds và điểm cấu hình ở results/cross_validation.json. Các ảnh kết quả là PNG, không tái nén JPEG khi chèn báo cáo.

C Hồ sơ nhóm

Nhật ký nhóm, đánh giá chéo và kế hoạch trách nhiệm ở docs/nhat_ky_nhom.csv, docs/danh_gia_cheo.csv và HUONG_DAN.md. Các biểu mẫu chưa điền không chứng minh hoạt động đã diễn ra. Nhóm cập nhật ngày họp, quyết định, commit và chữ ký thật trước khi nộp.

Phụ lục Sử dụng công cụ AI và hoàn thiện dữ liệu

D Khai báo sử dụng công cụ AI

Codex hỗ trợ tạo cấu trúc dự án, mã NumPy, script thí nghiệm, giao diện demo và bản thảo tài liệu. Trong phiên chuẩn bị đã chạy đối chiếu thuật toán với thư viện và thực nghiệm UCI. Nhóm sinh viên cần tự đọc, chạy lại, sửa theo dữ liệu thu thập và có khả năng giải thích từng phần được giao. Khai báo này không thay sự xác nhận của nhóm về tính đúng của sản phẩm cuối.

Phần nhóm tự kiểm tra sau khi nhận mã [Ghi người thực hiện, ngày, lệnh chạy và kết quả]. Phần nhóm điều chỉnh [Ghi cấu hình, dữ liệu, commit và lý do]. Không ghi những hoạt động chưa làm thành công việc đã hoàn thành.

E Danh mục hoàn thiện trước khi nộp

Thu ít nhất 100 ảnh thật tại ruộng hoặc vườn và xác nhận nhãn theo taxonomy. Tạo ít nhất 30 cặp mask tay độc lập cho segtest, có tập segval riêng. Nhập dữ liệu cà phê nếu giữ cả hai cây trong phạm vi thí nghiệm. Kiểm tra ảnh trùng và nhóm cây/phiên trước khi khóa test.

Chạy lại thí nghiệm, cập nhật Bảng 4 6 và kết luận mục tiêu bằng số liệu thật. Thêm phân tích sai số và so sánh miền; không để trạng thái chưa đo biến thành dấu 0 trong bảng chỉ số. Điền danh tính, liên kết repo và đóng góp. Hoàn thiện slide 15–20 trang, video thao tác thật 5–7 phút và chữ ký theo mẫu của khoa.

Các tệp báo cáo có thể cập nhật bằng scripts/build_report.py sau khi kết quả JSON thay đổi. Kiểm tra toàn bộ trang PDF sau mỗi thay đổi nội dung hoặc bảng. Tài liệu định hướng việc thực hiện và giải thích; kết quả thu thập thực địa, sự đồng thuận nhãn và quá trình nhóm phải do nhóm thực hiện và lưu minh chứng.